



AI Agent Nedir?

AI Agent Nedir?

Tanım



AI Agent, belirli bir hedef doğrultusunda **karar verebilen**, gerektiğinde **araç kullanabilen** ve sonucu üretmek için **eylem gerçekleştirebilen** yapay zeka sistemidir.

Temel Özellikler



Hedef Odaklı

Belirli bir işi tamamlamaya çalışır.



Karar Verebilir

Duruma göre sonraki adımı belirler.



Eylem Alabilir

Bilgi toplar, işlem yapar ve çıktı üretir.

Kısa Gerçek Hayat Örnekleri



Toplantı Hazırlığı

Gündemi toplar, notları düzenler, kısa özet hazırlar.



Müşteri Talebi

Talebi anlar, ilgili bilgiyi bulur, uygun yanıtı oluşturur.



Raporlama

Veriyi derler, önemli noktaları çıkarır, rapor oluşturur.

LLM ve AI Agent Arasındaki Fark

LLM



Örnek istek:

Yarınki toplantı için rakip firmalar hakkında kısa bilgi ver.

- Tek girdiye karşılık yanıt üretir.
- Çoğu zaman tek adımlıdır.
- Araç kullanımı zorunlu değildir.
- İş doğrudan tamamlamaz, içerik üretir.



Örnek çıktı:

Kısa bir metin yanıtı oluşturur.



Odak

LLM: yanıt üretimi
Agent: görev tamamlama



Adım Sayısı

LLM: çoğu zaman tek adım
Agent: çok adımlı olabilir

AI Agent



Örnek istek:

Yarınki toplantı için rakip firmalar hakkında kısa bilgi ver.

- Hedefe yönelik hareket eder.
- Birden fazla adımı planlayabilir.
- Web, dosya veya diğer araçları kullanabilir.
- Bilgiyi toplayıp görevi tamamlamaya çalışır.



Örnek çıktı:

Bilgi toplar, özetler ve kullanıma hazır sonuç oluşturur.



Araç Kullanımı

LLM: sınırlı
Agent: aktif




Çıktı

LLM: metin
Agent: işlem + sonuç


Agent Nasıl Çalışır?



Türkiye Yapay Zeka Akademisi



Agent'in Temel Bileşenleri



Otonomi Seviyesi ve Agent Davranışı



AI Agent Kullanım Alanları



Araştırma ve Bilgi Toplama

- Web'de araştırma yapar
- Farklı kaynakları analiz eder
- Özet ve rapor oluşturur



Müşteri Hizmetleri

- Müşteri sorularını yanıtlar
- Talep ve şikayetleri yönetir
- Gerekli sistemlerde işlem yapar



Yazılım Geliştirme

- Kod yazar ve düzenler
- Hata ayıklar ve test eder
- Proje üzerinde adımları takip eder



Veri Analizi

- Verileri toplar ve işleme alır
- Analizler yapar
- Grafik ve rapor üretir




Kişisel Asistanlar

- Takvim ve e-postayı yönetir
- Hatırlatıcılar oluşturur
- Günlük görevleri planlar



İş Süreçlerinin Otomasyonu

- Tekrarlayan görevleri otomatikleştirir
- Sistemler arasında işlem yapar
- İş akışlarını yönetir





Tool ve Tool Calling

Tool ve Tool Calling



Tool Tanımı: Description ve Schema



Description

Tool'un ne zaman ve hangi amaçla kullanılacağını açıklar.

- Hangi durumda kullanılacağını belirtir
- Modelin doğru tool'u anlamasını kolaylaştırır
- Kısa, net ve yönlendirici olmalıdır

ÖRNEK DESCRIPTION

"Bir şehir için güncel hava durumunu getirir.
Kullanıcı hava durumu sorduğunda kullanılır."



Schema

Tool'un hangi parametreleri, hangi veri tiplerinde beklediğini tanımlar.

- Parametre adlarını tanımlar
- Veri tiplerini belirtir
- Zorunlu ve opsiyonel alanları gösterir

ÖRNEK SCHEMA

```
{  
  city: string,  
  date: string,  
  unit: string (opsiyonel)  
}
```



Örnek Tool Tanımı



Description

"Belirli bir şehir için hava durumunu getirir.
Kullanıcı hava durumu sorduğunda kullanılır."



Schema

```
{  
  city: "Ankara",  
  date: "bugün"  
}
```



Description kullanım amacını, Schema ise beklenen parametre yapısını tanımlar.

Birden Fazla Tool ve Tool Seçimi



Türkiye Yapay Zeka Akademisi

Birden Fazla Tool

Tek bir model, farklı amaçlara hizmet eden birden fazla araca erişebilir.



Web Arama

Güncel bilgi ve dış kaynak araştırması



Veri Tabanı

Kayıt, tablo ve kurumsal veriye erişim



Kod Çalıştırma

Hesaplama, analiz ve veri işleme




E-posta / Mesajlaşma

Bildirim, gönderim ve iletişim işlemleri

Tool Seçimi

Tool Selection, mevcut görev için hangi aracın kullanılacağına karar verilmesidir.




Kısa Örnekler



Her tool farklı bir amaç için vardır; model, göreve göre en uygun aracı seçer.

Tool Call Akışı



Structured Output






Workflow ve Agent Arasındaki Fark

Workflow ve Agent Arasındaki Fark



Workflow

Önceden belirlenmiş işlem adımlarını sırasıyla takip eden sistemdir.




Öne Çıkan Özellikler

- İşlem adımları önceden tanımlıdır.
- Her zaman aynı akış takip edilir.
- Karar noktaları sınırlıdır veya yoktur.
- Daha öngörülebilir ve kontrol edilebilir.
- Tekrarlanabilir, stabil süreçler için uygundur.



AI Agent

Görevin nasıl tamamlanacağına çalışma sırasında karar verebilen, esnek ve dinamik bir sistemdir.



Öne Çıkan Özellikler

- Adımlar çalışma sırasında belirlenir.
- Duruma göre farklı araçlar ve yöntemler kullanılabilir.
- Sonuçları değerlendirip yeni kararlar verebilir.
- Esnek ve dinamik çalışır.
- Açık uçlu ve karmaşık görevler için uygundur.

Temel Workflow Desenleri



Türkiye Yapay Zeka Akademisi

1 Prompt Chaining

Birden fazla LLM adımının ardışık olarak çalıştırılmasıdır.



Nasıl Çalışır?

- 1 İlk LLM, görevi anlar ve bir ara çıktı üretir.
- 2 İkinci LLM, bu çıktıyı kullanarak bir sonraki adımı gerçekleştirir.
- 3 Son LLM, nihai sonucu oluşturur.




Ne Zaman Tercih Edilmeli?

- Görevin adımlara bölünebildiği durumlarda.
- Her adımın farklı bir uzmanlık gerektirdiği senaryolarda.
- Daha kontrollü ve öngörülebilir bir süreç istendiğinde.

2 Routing

Girdiyi analiz ederek uygun akışa yönlendiren bir desendir.



Nasıl Çalışır?

- 1 Model, kullanıcının isteğini analiz eder.
- 2 En uygun akışı belirler.
- 3 İsteği ilgili akışa yönlendirir ve sonucu döndürür.




Ne Zaman Tercih Edilmeli?

- Farklı konular veya niyetler için farklı işlemler gerektiğinde.
- Sınıflandırma veya yönlendirme ihtiyacı olduğunda.
- Doğru araca/uzmana hızlı ulaşmak istendiğinde.

3 Parallelization

Bağımsız işlemlerin eş zamanlı olarak çalıştırılmasıdır.



Nasıl Çalışır?

- 1 Görev, bağımsız alt görevlere bölünür.
- 2 Her alt görev eş zamanlı olarak çalıştırılır.
- 3 Sonuçlar birleştirilerek nihai çıktı oluşturulur.



Ne Zaman Tercih Edilmeli?

- Birbirinden bağımsız işlemler olduğunda.
- Hız ve verimlilik gerektiğinde.
- Paralel çalıştırmanın mümkün olduğu senaryolarda.

Tool Calling'den Agent'a Geçiş




Türkiye Yapay Zeka Akademisi



Tool Calling

Tek bir işlemi gerçekleştirmek için modelin bir tool'u çağırmasıdır.



Özellikleri

- Genellikle tek bir işlem için kullanılır.
- Model bir tool seçer ve parametreleri belirler.
- Tool çalıştırılır ve sonuç modele verilir.
- Ek adım planlaması veya dinamik karar verme yoktur.



Örnek Kullanım

- Hava durumu bilgisi alma
- Veri tabanından tek bir kayıt çekme
- Bir e-posta gönderme
- Basit bir hesaplama yapma



AI Agent

Görevi tamamlamak için birden fazla adımda karar verebilen, tool kullanabilen ve dinamik çalışan sistemdir.



Özellikleri

- Birden fazla adım planlayabilir.
- Sonuçlara göre yeni kararlar verebilir.
- Birden fazla tool kullanabilir.
- Görevi tamamlayana kadar döngüsel (agent loop) çalışır.
- Esnek ve dinamik bir yapıya sahiptir.



Örnek Kullanım

- Araştırma yapıp rapor oluşturma
- Farklı kaynaklardan veri toplayıp analiz etme
- Çok adımlı iş süreçlerini tamamlama
- Karar gerektiren ve duruma göre yaklaşım değiştiren görevler

Çok Adımlı Görevler ve Agent Loop



Türkiye Yapay Zeka Akademisi



Multi-Step Task Nedir?

Tek bir model veya tool çağrısıyla tamamlanamayan; birden fazla karar, işlem ve ara sonuç gerektiren görevdir.



Örnek Görev:

"Yarınki toplantı için rakip firmalar hakkında kısa bir rapor hazırla."

1



Rakip firmaları belirle

2



Web ve veri kaynaklarını tara

3



Bilgileri karşılaştır ve filtrele

4



Eksik bilgi varsa yeni arama yap

5



Kısa rapor oluştur



Görev, ara kararlar ve birden fazla işlem gerektirir.



Agent Loop Nasıl Çalışır?



Neden Agent Loop Gerekli?



Tek adım yetmediğinde süreci yönetir



Sonuca göre yeni karar verebilir



Birden fazla tool ve bilgi kaynağı kullanabilir



Görevi tamamlanana kadar kontrollü şekilde ilerler



Çok adımlı görevlerde agent, her ara sonuca bakarak sonraki adımı belirler ve görev tamamlanana kadar döngüsel çalışır.

Stop Condition ve Sınırlar

Stop Condition

Stop Condition, agent loop'un tamamlandığını belirleyen koşuldur.



Execution Limits / Sınırlar

Execution Limits, agent'in kontrolsüz veya gereksiz şekilde çalışmasını engelleyen sınırlardır.



Maksimum Adım Sayısı

En fazla kaç döngü çalışacağı belirlenir.



Süre Sınırı

Belirli bir süreden sonra işlem durdurulur.



Tool / İşlem Sayısı

Çağrılacak tool veya işlem sayısı sınırlandırılır.



Maliyet / Kaynak Sınırı

Token, API veya işlem maliyeti kontrol altında tutulur.

Neden Gerekli?



Kontrol sağlar



Sonsuz döngüyü önler



Maliyet ve zamanı sınırlar



Daha güvenli çalışma sağlar




Stop condition agent'in ne zaman duracağını, sınırlar ise ne kadar çalışabileceğini belirler.

Hata Yönetimi ve Retry



Türkiye Yapay Zeka Akademisi



Olası Hata Türleri



Ağ / Bağlantı Hatası
API'ye ulaşamaması veya
ağ kesintisi.

Örnek
ConnectionError
Timeout



API Hatası
Sunucu tarafı hata veya
yanıt alınamaması.

Örnek
HTTP 500
Service Unavailable



Geçersiz Girdi Hatası
Yanlış veya eksik parametreler.

Örnek
HTTP 400
Invalid parameters



Limit Aşımı
Rate limit, kota veya
zaman aşımı.

Örnek
HTTP 429
Rate limit exceeded



Beklenmeyen Hata
Tool veya model tarafında
öngörülemeyen hatalar.

Örnek
JSON parse error
Unknown error

Retry Stratejileri



Sabit Aralık

Her denemede aynı
süre beklenir.

- deneme: 2 sn
- deneme: 2 sn
- deneme: 2 sn



Üssel Geri Bekleme (Exponential Backoff)

Her denemede bekleme
süresi artar.

- deneme: 1 sn
- deneme: 2 sn
- deneme: 4 sn



Rastgele Gecikme (Jitter)

Aşırı yüklenmeyi engellemek
için rastgele süre eklenir.

- 2 sn + [0-1 sn]
- 4 sn + [0-2 sn]
- 8 sn + [0-4 sn]



Sınırlı Deneme Sayısı

Maksimum deneme
sayısı belirlenir.

- max_retries = 3
başarısız
işlem durdurulur

Dikkat Edilmesi Gerekenler

- ✓ Tüm hatalar için tekrar denemek uygun değildir (örn. geçersiz girdi).
- ✓ Maksimum deneme sayısı mutlaka sınırlandırılmalıdır.
- ✓ Bekleme süreleri, API limitlerine ve kullanım senaryosuna göre ayarlanmalıdır.
- ✓ Hata durumunda anlamlı bir mesaj üretilmeli ve gerekirse alternatif adımlar planlanmalıdır.



Türkiye Yapay Zeka
Akademisi


Yapay Zekayı Keşfet
Geleceği İnşa Et

State Nedir?

State Nedir?



State, Context ve Memory Farkı



Stateless ve Stateful Agent



Türkiye Yapay Zeka Akademisi



Stateless Agent

Her çağrıyı bağımsız değerlendirir; önceki çalışma durumunu korumaz.




Örnek:

İlk çağrıda araştırma yapıldı, ikinci çağrıda rapor kısaltma isteği geldi; sistem önceki adımı otomatik hatırlamaz.



Stateful Agent

Çalışma durumunu korur ve sonraki adımlarda mevcut state bilgisini kullanabilir.



Örnek:

İlk çağrıda bulunan firmalar saklanır; ikinci çağrıda agent bu bilgileri kullanarak kısa rapor oluşturur.



Durum Yönetimi

Çalışma durumunun (state) korunup korunmaması

Stateless Agent

Yok veya geçici

Stateful Agent

Korunur



Uygun Görevler

Hangi tür görevler için daha uygundur

Stateless Agent

Tek seferlik işler

Stateful Agent

Çok adımlı işler



Devamlılık

Önceki adımların kullanılabilmesi

Stateless Agent

Düşük

Stateful Agent

Yüksek

Short-Term Memory ve Conversation History



Sessions



Türkiye Yapay Zeka Akademisi



Session, belirli bir kullanıcıya veya konuşmaya ait state ve geçmiş bilgilerin ilişkilendirildiği çalışma bağlamıdır. Her session, kendi conversation history, mevcut görev, ara sonuçlar ve diğer bilgilerle birlikte yönetilir.

Örnek: Tek Bir Session



session_id: s1

- Conversation History (mesaj geçmişi)
- Mevcut Görev (rakip analizi)
- Ara Sonuçlar (firma listesi, özet)
- Kullanılan Araçlar (web_search, pdf_reader)
- Diğer Bilgiler (tercihler, notlar vb.)

Session Storage (Bellek / Veritabanı)



session_id: s1

Conversation History	K: Yarınki toplantı için... A: Hangi sektör için...? K: Bulut bilişim sektörü olsun. A: Tamam, ilk 3 firmayı... K: Bu firmaları karşılaştı... A: İşte karşılaştırma ve nihai rapor...
Mevcut Görev	Rakip analizi
Ara Sonuçlar	Firma listesi, karşılaştırma tablosu
Kullanılan Araçlar	web_search, pdf_reader
Diğer Bilgiler	Kullanıcı tercihi, geçmiş notlar

Neden Session Kullanılır?



Kullanıcıları Ayırır

Farklı kullanıcıların konuşma geçmişi ve state bilgisi birbirinden bağımsız tutulur.



Tutarlı Deneyim Sağlar

Aynı session içinde önceki mesajlar ve ara sonuçlar kullanılabilir.



State ve Hafızayı İlişkilendirir

Belirli bir konuşmaya ait görev, state ve memory bilgileri aynı session altında saklanır.



Uzun Süreli Etkileşimleri Destekler

Kullanıcı farklı zamanlarda tekrar geldiğinde kaldığı yerden devam edebilir.

Long-Term Memory



Türkiye Yapay Zeka Akademisi



Long-Term Memory, kullanıcı veya görev bilgilerinin farklı oturumlar (session) arasında kalıcı olarak saklandığı hafızadır. Bir session sona erdikten sonra da kullanılmaya devam eden uzun vadeli bilgilerdir.

Konuşmalar (Farklı Sessions)



Session 1

"Teknoloji haberlerini takip ediyorum."



Session 2

"Raporları PDF olarak istiyorum."



Session 3

"Derin öğrenme ile ilgili kaynak öner."



Önemli bilgiler çıkarılır ve uzun vadeli hafızaya kaydedilir.



Agent
(LLM + Tools)

Yeni bir session'da gerektiğinde ilgili bilgileri getirir.

Memory Management

- Önemli bilgileri belirler
- Özetleyerek kaydeder
- Gereksiz bilgileri filtreler
- Zamanla günceller

Long-Term Memory Storage



Vector Database
(veya diğer veritabanı)

Ne saklanır?

- Kullanıcı tercihleri
- Uzun vadeli hedefler
- Önemli bilgiler
- Özetlenmiş geçmiş


Nasıl saklanır?

- Metin olarak (özetlenmiş)
- Embedding (anlamsal arama)
- Metadata ile (tarih, konu, kaynak)
- Veritabanında kalıcı olarak

Yeni Session



"Geçen konuşmamızdaki tercihlerime göre önerilerin var mı?"



Long-Term Memory'den ilgili bilgiler getirilir ve cevapta kullanılır.

Long-Term Memory Nasıl Oluşturulur?



1. Bilgileri Seçme

Her bilgiyi değil, önemli ve kalıcı olanları seçme.



2. Özetleme

Uzun konuşmaları özetleyerek kaydetme.



3. Metadata Ekleme

Konu, tarih, kullanıcı, kaynak gibi bilgiler ekleme.



4. Embedding Oluşturma

Bilgiyi vektöre çevirip anlamsal arama için saklama.



5. Güncelleme

Yeni bilgilerle güncelleme, gereksiz olanları silme.

Long-Term Memory Türleri / Saklama Yöntemleri



Metin Tabanlı

- Özetlenmiş bilgiler
- JSON / Database



Vektör Tabanlı

- Embedding ile saklama
- Anlamsal benzerlik arama



Hibrit Yaklaşım

- Hem metin hem vektör
- Metadata ile birlikte saklama

Semantic Memory ve Vector Database



Türkiye Yapay Zeka Akademisi



Semantic Memory

Kullanıcının ilgi alanları, tercihler, hedefleri, önceki etkileşimlerden çıkarılan anlamlı bilgilerin (facts, concepts) vektör temsilleriyle saklandığı uzun vadeli hafızadır.



Vector Database

Metin, belge veya çıkarılan bilgilerin embedding (vektör) olarak saklandığı ve anlamsal benzerlik aramasıyla hızlıca geri getirilebildiği veritabanıdır.

1. Bilgi (Metin)



Yapay zeka ve görüntü işleme alanında çalışıyorum.



Teknofest projelerine ilgi duyuyorum.



Python ile çalışmayı seviyorum.



2. Embedding (Vektörleştirme)



[0.023, -0.18, 0.41, 0.56, ...]

- Metin, embedding modeli ile sayısal vektöre çevrilir.
- Benzer anlamdaki metinler vektör uzayında birbirine yakın konumlanır.

3. Vector Database



[0.023, -0.18, 0.41, ...]

[-0.12, 0.33, 0.27, ...]

[0.45, 0.11, -0.09, ...]



4. Anlamsal Arama



"Daha önce önerdiğin görüntü işleme projesini hatırlatır mısın?"

Query Embedding

[0.02, -0.17, 0.39, ...]



Benzerlik Araması (cosine similarity)

5. İlgili Bilgiler (Semantic Memory)



Geçen ay paylaştığım OpenCV projesini deneyebilirsiniz.

0.92



Yüz tanıma ile ilgili projeyi de önermiştim.

0.87



Python ile görüntü işleme kaynakları burada.

0.81



Neden Semantic Memory?



Kişiselleştirme

Kullanıcıyı daha iyi tanıır, kişiselleştirilmiş yanıtlar üretir.



Uzun Vadeli Hafıza

Geçmiş oturumlardan edinilen bilgiler saklanır ve tekrar kullanılır.



Anlamsal Arama

Anahtar kelime yerine anlama dayalı arama ile daha ilgili sonuçlar getirilir.



Daha Doğru Kararlar

Kullanıcının tercih ve hedeflerine göre daha uygun öneriler sunulur.

Saklanabilecek Bilgiler ve Kaynaklar



Kullanıcı Bilgileri

- Tercihler
- İlgi alanları
- Hedefler
- Geçmiş işler / projeler



Belgeler

- PDF / DOC / TXT
- Notlar
- Raporlar
- Kurumsal dokümanlar



Konuşma Geçmişi

- Önemli bilgiler
- Çıkarılan özetler
- Kullanıcı soruları
- Verilen tavsiyeler



Harici Kaynaklar

- Web sayfaları
- Veritabanları
- API çıktıları
- Diğer sistemler

Memory Management



Türkiye Yapay Zeka Akademisi



Memory Management, agent'in hangi bilgiyi ne zaman, nasıl saklayacağını, nasıl kullanacağını ve gerektiğinde nasıl güncelleyeceğini belirleyen süreçtir. Amacı, doğru bilgiyi doğru zamanda kullanarak daha tutarlı, verimli ve güvenilir yanıtlar üretmektir.






Agentic RAG ve Klasik RAG Farkı

Agentic RAG ve Klasik RAG Farkı

Klasik RAG




- 1 Retrieval akışı sabittir.
- 2 Bilgi getirme adımı genellikle her soruda çalışır.
- 3 Pipeline önceden tanımlıdır.
- 4 Karar verme esnekliği düşüktür.



Örnek: Kullanıcı soru sorar, sistem doğrudan vektör veritabanından bilgi getirir ve cevabı üretir.

Agentic RAG



- 1 Retrieval kararı dinamik olarak verilir.
- 2 Agent, ne zaman bilgi getireceğine karar verir.
- 3 Bilgi getirme süreci daha esnek yönetilir.
- 4 Gerekirse retrieval yeniden tetiklenebilir.



Örnek: Agent önce elindeki bilginin yeterli olup olmadığını değerlendirir; gerekirse bilgi getirir, sonra cevabı oluşturur.

Akış

Klasik RAG	Agentic RAG
Sabit	Dinamik

Retrieval Tetikleme

Klasik RAG	Agentic RAG
Genellikle otomatik	İhtiyaca göre

Esneklik

Klasik RAG	Agentic RAG
Düşük	Yüksek

Kontrol

Klasik RAG	Agentic RAG
Pipeline odaklı	Agent odaklı

Retrieval'ı Tool Olarak Kullanmak




Türkiye Yapay Zeka Akademisi



Retrieval Tool Nedir?

- Harici bilgi kaynağından ilgili verileri getiren agent aracıdır.
- Vector database, doküman deposu veya kurumsal bilgi tabanına bağlanabilir.
- Agent bu tool'u diğer araçlar gibi çağırabilir.



Tool'un Girdi ve Çıktıları



Girdi (Parametreler)



query

Kullanıcının sorusu veya arama ifadesi



top_k

Getirilecek sonuç sayısı (örn. 3)



filters / collection

Hangi koleksiyonda aranacağı veya isteğe bağlı filtreler



Çıktı (Dönen Veriler)



İlgili chunk'lar

Soruya en alakalı metin parçaları (örn. 3 adet)



metadata

Her chunk için ek bilgiler (başlık, bölüm, tarih vb.)



kaynak bilgisi

Verinin geldiği doküman ve koleksiyon bilgisi



Kısa Örnek

1

Kullanıcı "LLM ajanları nedir?" diye sorar.

→

2

Agent, retrieval tool'unu çağırır.

→

3

Bilgi tabanından ilgili parçaları getirir.

→

4

Bu parçaları kullanarak nihai cevabı oluşturur.


Retrieval Kararı



Türkiye Yapay Zeka Akademisi



Retrieval Kararı, agent'ın mevcut bilgilerinin soruyu cevaplamak için yeterli olup olmadığını değerlendirmesi ve gerektiğinde retrieval yapıp yapmayacağına karar vermesidir.



Query Rewrite





Türkiye Yapay Zeka Akademisi



Query Rewrite

Query Rewrite, kullanıcı sorusunun daha kaliteli ve ilgili retrieval sonuçları elde etmek amacıyla yeniden oluşturulmasıdır.



Query Rewrite Teknikleri



Soru Genişletme

Önemli anahtar kelimeler ve bağlam eklenir.



Yeniden Formülasyon

Soru daha açık ve anlaşılır hale getirilir.



Çoklu Varyasyon

Aynı niyeti farklı şekillerde ifade eden birden fazla sorgu oluşturulur.



Bağlam Ekleme

Alan, konu, zaman veya belge türü gibi ek bilgiler eklenir.



Soru Türüne Göre Dönüştürme

Açıklama, örnek, karşılaştırma gibi niyete uygun formatta düzenlenir.




Gereksiz Belirsizlikleri Giderme

Kısaltmalar, muğlak ifadeler ve belirsiz referanslar netleştirilir.

Kaynak Seçimi



Kaynak seçimi, agent'ın mevcut görev için en uygun bilgi kaynağını (vector database, web, SQL veya farklı kaynaklar) değerlendirerek hangisini kullanacağına karar vermesidir.



Farklı Sorular, Farklı Kaynak Seçimleri



Retrieval Sonucunu Değerlendirme



Türkiye Yapay Zeka Akademisi

Retrieval sonucunu değerlendirme, getirilen bilginin soruyu cevaplamak için yeterli, ilgili ve güvenilir olup olmadığının agent tarafından kontrol edilmesidir.



Yeterli Sonuç Örneği

Sonuç Özeti

Uzaktan çalışma haftada en fazla 3 gün olarak tanımlanmıştır. Başvuru İK portalı üzerinden yapılır.

Neden Yeterli?

- ✓ Soruyla doğrudan ilgili
- ✓ Açık ve net bilgi içeriyor
- ✓ Güncel politika dokümanı
- ✓ Cevap üretmek için yeterli

Yetersiz Sonuç Örneği

Getirilen Sonuçlar (Örnek)

Sonuç 1	Esnek çalışma modelleri hakkında genel bilgiler...	0.54
Sonuç 2	Yan haklar ve şirket uygulamaları...	0.48

Neden Yetersiz?

- ⚠ Soru ile düşük ilgili
- ⚠ Ana bilgi eksik
- ⚠ Belirsiz / genel ifadeler var
- ⚠ Daha iyi sorgu veya yeni retrieval gerekli

Değerlendirme Kriterleri



Alaka Düzeyi

Getirilen bilginin soruyla ne kadar ilgili olduğunu ölçer.



Bilgi Kapsamı

Bilginin soruyu cevaplamak için yeterli ve açık olup olmadığını değerlendirir.



Doğruluk / Güvenilirlik

Bilginin doğru, tutarlı ve güvenilir bir kaynaktan gelip gelmediğini kontrol eder.



Güncellik

Bilginin güncel ve mevcut durumu yansıtmadığını değerlendirir.



Yeterlilik

Tüm kriterler birlikte değerlendirilerek cevap yeterli olup olmadığına karar verilir.

Multi-Step Retrieval



Çok Adımlı Arama Örneği





Context Engineering Nedir?

Context Engineering Nedir?



Türkiye Yapay Zeka Akademisi



Context Engineering, modelin doğru karar verebilmesi için doğru bilgiyi, doğru zamanda, doğru miktarda ve uygun düzenle sunma disiplini.

Görev / Kullanıcı İsteği



"Bu ayki satış düşüşünü özetle."



Context Tasarımı



alaka

Doğru bilgi

Görev için gerçekten gerekli bilgiler seçilir.



zamanlama

Doğru zaman

Bilgi ihtiyaç duyulan anda modele verilir.



yeterlilik

Doğru miktar

Eksik ya da aşırı değil, yeterli context sağlanır.



öncelik

Doğru düzen

Önemli bilgiler açık ve öncelikli şekilde sunulur.

Model Kararı / Yanıt



Daha doğru, odaklı ve ilgili yanıt

Neden Önemli?

- ✓ Daha tutarlı kararlar
- ✓ Daha ilgili yanıtlar
- ✓ Gereksiz bilgi yükünü azaltma
- ✓ Tool, retrieval ve memory kullanımını daha etkili hale getirme
- ✓ Hata ve dikkat dağınıklığını azaltma

Kısa Örnek



Kullanıcı isteği

"Bu ayki satış düşüşünü özetle."



İyi context tasarımı

- Son satış raporu
- İlgili tablo ve temel metrikler
- Kısa görev talimatı
- Gereksiz geçmiş mesajlar hariç



Sonuç

Model daha odaklı ve doğru bir özet üretir.



Anahtar Kavramlar



Seçim

Hangi bilgi dahil edilecek?



Filtreleme

Gereksiz bilgi dışarıda kalır.



Odak

Modelin dikkati ilgili bilgiye yönelir.



Netlik

Bilgi anlaşılır biçimde sunulur.



Karar Kalitesi

Daha iyi yanıt ve aksiyon üretimi

Prompt Engineering ve Context Engineering Farkı



Prompt Engineering

Modelden nasıl bir cevap istediğimizi belirleyen talimatın yazım biçimini, yapısını ve ifade şeklini tasarlama sürecidir.



Kullanıcı Sorusu




LLM

VS



Context Engineering

Modelin gördüğü toplam bilgi ortamını (talimat + geçmiş + bellek + retrieved belgeler + araç sonuçları vb.) tasarlama sürecidir.



LLM

Örnek



Aşağıdaki metni özetle.
Madde madde yaz, en fazla 5 madde olsun.



- 1
- 2
- 3
- 4
- 5

Örnek



2024 finansal sonuçlarımızı özetle. Önceki sorduğum rakip analizi ile karşılaştır ve önemli noktaları belirt.



- 1 2024 gelirleri %22 artarak 12.4M\$ oldu.
- 2 Karlılık %18 arttı, bu rakiplerin (%10) üzerinde.
- 3 Büyümenin ana nedeni yeni ürün lansmanları ve ABD pazarındaki genişleme.
- 4 2025 için beklentiler ve riskler ...

- Cevap; birden fazla kaynağın bir araya getirilmesiyle oluşturulur:**
- ✓ Şirket finansal raporu (retrieval)
 - ✓ Rakip verileri (web/SQL)
 - ✓ Önceki konuşma geçmişi
 - ✓ Kullanıcının ilgi alanları

Context Window ve Context Kaynakları



Türkiye Yapay Zeka Akademisi



Başlıca Context Kaynakları


Sistem Talimatları	Konuşma Geçmişi	Retrieval Sonuçları	Tool Sonuçları	Memory / State	Kullanıcı Mesajı
Sen bir finans analistin. Yanıtlarını tablo ile ver. Güncel verilere odaklan. ...	Kullanıcı: 2024 gelirleri? Asistan: 2024 gelirleri 12.4M TL oldu. Kullanıcı: Karlılık nasıl ...	2024_Finansal_Rapor.pdf (sayfa 12) Gelirler %22 arttı ... 2024_Sektor_Analizi.pdf ...	SELECT year, revenue FROM financials; 2024 12.4M 2023 10.2M 2022 8.1M	{ "kullanici_profil": "Finans", "tercih": "Tablo", "onceki_konu": "2024 sonuçları", ... }	2024 finansal sonuçlarımızı özetle. Önceki sorularıyla bağlantılı olarak karlılık ve önemli noktaları da ekle.

Context Selection ve Filtering



Türkiye Yapay Zeka Akademisi

💡 Context selection, görev için hangi bilgilerin context'e alınacağını; filtering ise alakasız, düşük değerli veya dikkat dağıtıcı bilgilerin dışarıda bırakılmasını belirler.



Context Trimming ve Compression



Türkiye Yapay Zeka Akademisi



Context trimming, uzayan context içindeki eski, düşük öncelikli veya artık gerekli olmayan parçaların çıkarılmasıdır; compression ise önemli bilginin anlam korunarak daha kısa bir temsile dönüştürülmesidir.



Trimming (çıkarma)

Eski veya düşük öncelikli içerik context'ten tamamen çıkarılır.

Uzun Context (Öncesi)

- Sistem talimatı
- Mevcut kullanıcı sorusu
- Son retrieval sonucu
- Son tool çıktısı
- Eski konuşma mesajları
- Tekrarlı açıklamalar
- Eski log kayıtları

Trimmed Context (Sonrası)

- Kısa sistem talimatı
- Mevcut kullanıcı sorusu
- Son retrieval sonucu
- Gerekli tool çıktısı



Neler çıkarılabilir?

- Eski mesajlar
- Tekrarlı içerik
- Düşük öncelikli detaylar
- Artık gerekli olmayan ara çıktılar



Etkisi

Token kullanımı azalır ve model güncel göreve odaklanır.



Compression (sıkıştırma)

Uzun içerik atılmaz; daha kısa ama anlamı korunmuş bir temsile dönüştürülür.

Uzun içerik (Öncesi)

Satışlar Q2'de düştü. En büyük neden distribütör kanalındaki daralma ve iki büyük müşteride sipariş ertelenmesiydi. Pazarlama maliyetleri arttı, kârlılık baskılandı. Ayrıca bazı bölgelerde stok sorunları yaşandı ve yeni ürün lansmanı planlandığı gibi ilerlemedi. Rekabetin artması da fiyatlar üzerinde baskı oluşturdu. Genel olarak, hem iç hem de dış faktörler bir araya gelerek Q2'deki düşüşte etkili oldu.

Compressed Context (Sıkıştırılmış özet)

- Q2 satış düşüşü
- Neden: distribütör daralması + sipariş ertelenmesi
- Kârlılık: artan pazarlama maliyeti nedeniyle baskılandı



Ne korunur?

- Ana anlam
- Temel karar bilgisi
- Kritik sayılar / bulgular



Etkisi

Daha az token ile önemli bilgiyi korur.



Kısa Karşılaştırma

Özellik	Trimming (çıkarma)	Compression (sıkıştırma)
Amaç	Gereksiz içeriği kaldırmak	Uzun içeriği kısaltmak
İşlem	Silme / çıkarma	Özetleme / yeniden temsil
Ne olur?	Bazı içerik tamamen gider	İçerik kalır ama daha kısa hale gelir

Kısa Örnek



Kullanıcı isteği: "Bu çeyrekte satışların neden düştüğünü özetle."



Trimming (çıkarma):

Geçen yılın alakasız kampanya konuşmaları çıkarılır.



Compression (sıkıştırma):

Uzun satış toplantısı notları kısa özet haline getirilir.



Sonuç: Model daha kısa ve daha faydalı bir context ile çalışır.

Context Budgeting



Türkiye Yapay Zeka Akademisi



Context budgeting, kullanılabilir context kapasitesinin instructions, history, state, memory, retrieval ve tool sonuçları arasında bilinçli biçimde dağıtılmasıdır.



Toplam Context Bütçesi

128K token (örnek)



Bütçe Dağıtımı Nasıl Yapılır?



Görev türü

Analiz, özet, kodlama, çok adımlı görev gibi farklı türler farklı alan ihtiyacı doğurur.



Güncellik ihtiyacı

Daha güncel bilgi gerekiyorsa retrieval ve tool sonuçlarına daha fazla alan ayrılır.



Kaynak sayısı

Kullanılacak doküman, veri tablosu, rapor ve araç sayısı arttıkça ilgili bölümlere daha fazla bütçe gerekir.



Beklenen çıktı uzunluğu

Kısa yanıtlar daha az, detaylı raporlar daha fazla alan gerektirir.



Model sınırı ve maliyet

Modelin maksimum context sınırı ve token maliyeti, dağıtımı belirler.



Örnek Görev

"2024 satış düşüşünün nedenlerini, rakiplerle karşılaştırarak kısa bir yönetici özeti halinde hazırla."

Örnek Bütçe Planı

- 1 Retrieval için daha fazla alan ayrılır.
- 2 İlgili tablo ve rapor parçaları alınır.
- 3 Uzun geçmiş yerine kısa konuşma özeti kullanılır.
- 4 Cevap için yeterli alan bırakılır.
- 5 Gereksiz tool çıktıları eklenmez.



İyi Bütçeleme Ne Sağlar?



Daha ilgili context

En önemli bilgiler için yeterli alan ayrılır.



Daha az dikkat dağınıklığı

Gereksiz bilgiler yerine görevle ilgili içerik öne çıkar.



Daha tutarlı yanıt

Model kritik bilgileri kaçırmadan daha dengeli yanıt verir.



Token verimliliği

Aynı bütçe ile daha yüksek fayda sağlanır.



Daha iyi araç ve retrieval kullanımı

Araç sonuçları ve retrieved bilgiler için uygun alan ayrılır.



Bir kaynağa fazla bütçe ayırmak, diğer kritik bilgiler için alanı azaltır.

Retrieval'a çok fazla alan ayrıldığında

80K

Diğer bileşenler için daha az alan kalır.

Daha dengeli bir dağıtım

Tüm bileşenler için yeterli alan sağlanır.

Context Noise, Context Rot ve Tasarım Prensipleri



Türkiye Yapay Zeka Akademisi



Context noise, gereksiz veya düşük değerli bilginin modelin dikkatini dağıtmasıdır; **context rot** ise context büyüdükçe önemli bilginin etkisinin azalması ve yapının bozulması problemidir.



Context Noise

Context içinde alakasız, tekrarlı veya düşük değerli bilgi olması modelin dikkatini dağıtır.

Karmaşık ve Gürültülü Context

- Alakasız konuşma geçmişi**
"Dün hava çok güzeldi..."
- Tekrarlı retrieval parçaları**
"Aynı dokümanın tekrarları..."
- Gereksiz tool çıktıları**
"Detaylı ve uzun log çıktıları..."
- Eski mesajlar**
"Geçen ayki toplantı notları..."
- Uzun ama düşük değerli açıklamalar**
"Genel bilgiler, arka plan metinleri..."



Etkileri

- Dikkat dağılır**
Model ilgili bilgiye odaklanmakta zorlanır.
- İlgili bilgi görünmez hale gelir**
Önemli bilgiler gürültü içinde kaybolur.
- Yanıt kalitesi düşebilir**
Daha yüzeysel veya hatalı yanıtlar üretilebilir.
- Token bütçesi boşa gider**
Sınırlı token alanı verimli kullanılamaz.



Context Rot

Context büyüdükçe önemli bilginin etkisi azalır, eski bilgiler baskın hale gelir ve yapının bütünlüğü bozulur.

Zamanla Büyüyen Context

- Eski konuşmalar** 1 ay önce
"Geçen ayki planlama notları..."
- Retrieval parçaları** 3 hafta önce
"Ürün dokümantasyonu..."
- Eski tool çıktıları** 2 hafta önce
"Detaylı log kayıtları..."
- Tekrarlı içerikler** 1 hafta önce
"Aynı bilgilerin farklı sürümleri..."
- Önemli ve güncel bilgi** Şimdi
"Bu çeyreğe ait satış raporu..."

Önemli bilgi aşağıda kaldı.



Etkileri

- Öncelik kaybı**
Model eski ve alakasız bilgilere daha fazla ağırlık verebilir.
- Eski bilgiye aşırı bağlılık**
Güncel bilgi yerine eski bağlam kullanılabilir.
- Çelişkili veya zayıf yanıt**
Farklı zamanlardaki bilgiler arasında tutarsızlık oluşabilir.
- Uzayan context ile performansın bozulması**
Context büyüdükçe modelin anlama ve takip etme yeteneği azalabilir.



Tasarım Prensipleri

Context noise ve context rot sorunlarını azaltmak için şu prensipleri uygulayın.



Seçici Ol

Sadece görev için gerçekten gerekli bilgiyi ekle.



Filtrele

Alakasız, tekrarlı ve düşük kaliteli içeriği çıkar.



Önceliklendir

En kritik bilgileri daha görünür ve üstte sun.



Güncel Tut

Eski veya geçersiz bilgileri ayıkla.



Kısalt / Sıkıştır

Uzun içeriği anlamı koruyarak özetle.



Tutarlı Yapı Kur

Context'i düzenli, okunabilir ve segmentli ver.



Kısa Örnek

Kullanıcı isteği:
"Bu çeyrekte satışların neden düştüğünü özetle."



Kötü context

- Eski kampanya mesajları (3 ay öncesi)
- Tekrarlı log kayıtları (uzun ve teknik detaylar)
- Alakasız sohbetler (genel konuşmalar)
- ...



İyi context

- Bu çeyreğe ait satış raporu (özet ve temel metrikler)
- İlgili ürün/hizmet kırılımları (güncel veriler)
- Güncel yönetici notu (nedenlere dair değerlendirme)
- ...



Sonuç

Temiz context, daha net ve güvenilir analiz sağlar.



Planning Nedir?

Planning Nedir ve Task Decomposition



Planning:

Agent'ın hedefe ulaşmak için izleyeceği adımları belirleme sürecidir.



Task Decomposition:

Büyük bir görevin daha küçük, net ve yönetilebilir alt görevlere ayrılmasıdır.



İyi bir plan ne içerir?



Net hedef



Alt görevler



Bağımlılıklar ve sıra



Araç / kaynak seçimi



Beklenen çıktı

Task Decomposition İlkeleri



Her alt görev tek bir amaca hizmet etmeli



Çıktısı net olmalı



Gerekirse paralel çalışabilmeli



Bir sonraki adıma girdi sağlamalı



Karmaşık görevleri yönetilebilir hale getirir



Doğru tool ve veri kaynağı seçimini kolaylaştırır



İzlenebilir ve hatası ayıklanabilir süreç sağlar

ReAct: Düşün, Hareket Et, Gözlemle



Türkiye Yapay Zeka Akademisi



ReAct, agent'ın reasoning ve action adımlarını dönüşümlü kullanarak gözlemler üzerinden bir sonraki kararını vermesini sağlayan çalışma desenidir.



Kısa Örnek

1



Soru:

En uygun fiyat/performans laptopları araştır.



2



Düşün:

Önce güncel modelleri bulmalıyım.



3



Hareket Et:

Web araması yap.



4



Gözlemle:

Modeller bulundu, şimdi teknik özellikleri karşılaştır.

ReAct ne zaman güçlüdür?



Bilgi dış dünyadan geliyorsa



Tek adımda çözülemeyen görevlerde



Sonuçlara göre yeni karar gerekiyorsa



Tool kullanımı merkezdeyse



Temel fikir

Agent önce düşünür, sonra eylem yapar, sonucu gözlemler ve gerekiyorsa döngüyü tekrar ederek görevi tamamlar.

Plan-and-Execute Deseni



Türkiye Yapay Zeka Akademisi



Plan-and-Execute, agent'ın önce genel bir plan oluşturup ardından bu planın adımlarını yürütmesiyle çalışan agent deseni.



Desenin Akışı



Kısa Gerçek Örnek



2024 satış performansını analiz et ve yönetici özeti hazırla.



Planner:

Önce veriyi topla, sonra ürün/bölge bazında analiz yap, ardından önemli bulguları çıkar.



Executor Adım 1:

SQL'den satış verilerini getirir



Executor Adım 2:

Ürün ve bölge bazında analiz yapar



Executor Adım 3:

Önemli bulguları derler



Executor Adım 4:

Yönetici özeti üretir



Ne zaman kullanılır?



Uzun ufuklu görevler

Birden fazla adım gerekiyorsa



Önceden planlama faydalıysa

Sıra ve bağımlılıklar önemliyse



Tool kullanımı yoğunsa

Her adım farklı araç gerektiriyorsa



İzlenebilirlik isteniyorsa

Plan ve uygulama ayrıştırılmak isteniyorsa



Temel Özellikler



Planner-Executor ayrımı

Düşünme ve uygulama ayrılır



Daha az anlık karar

Her adımda yeniden plan yapmaz



Daha düzenli iş akışı

Adımlar baştan görünür



Kolay izleme / debug

Hangi adımda sorun olduğu görülebilir



Gerekirse yeniden planlama

Bazı tasarımlarda plan güncellenebilir



Temel fikir

Önce plan yapılır, sonra executor bu planı uygular; bu yaklaşım özellikle çok adımlı ve izlenebilir görevlerde güçlüdür.

Reflection ve Replanning



Türkiye Yapay Zeka Akademisi



Agent, önceki adımlardan aldığı geri bildirimlere dayanarak **hatalarını analiz eder (reflection)** ve gerekirse **planını güncelleyerek (replanning)** daha iyi bir sonuç elde etmek için yeni bir yol izler.



Gerekirse tekrar değerlendir ve planı güncelle



Reflection için Yaygın Yöntemler



Self-Reflection
Kendi çıktısını eleştirir ve iyileştirme önerileri üretir.



Critic Model
Aynı bir model çıktıyı değerlendirir, hataları belirler.



Feedback from Tools
Araçlardan gelen hata mesajlarını kullanır.



Self-Correction
Hatalı adımları düzelterek yeniden dener.



Replanning için Yaygın Yöntemler



Plan Revision
Mevcut planı güncelleyip yeni adımlar ekler.



Dynamic Planning
Ara sonuçlara göre dinamik olarak plan değiştirir.



Tree of Thoughts (ToT)
Birden fazla alternatif plan üretip en iyisini seçer.



ReAct + Reflection
Düşünme + eylem döngüsünü geri bildirimle güçlendirir.



Multi-Agent Nedir ve Neden Kullanılır?

Multi-Agent Nedir ve Neden Kullanılır?



Türkiye Yapay Zeka Akademisi



Multi-agent sistem, tek bir hedefi gerçekleştirmek için birden fazla agent'ın uzmanlaşmış rollerle birlikte çalıştığı yapıdır. – Amaç, karmaşık işleri bölmek, paralelleştirmek ve daha güvenilir sonuç üretmektir.



Neden Kullanılır?



Tek Agent yerine ne zaman?

- 1 Görev çok adımlıysa.
- 2 Farklı uzmanlıklar gerekiyorsa.
- 3 Birden fazla veri kaynağı kullanılıyorsa.
- 4 Doğrulama / review önemliyse.

Gerçek Kullanım Örneği



Güncel Ekosistem / Framework Örnekleri



Bu araçlar rol dağıtımı, koordinasyon ve çok-agent akışları tasarlamak için kullanılır.

Specialized Agents



Türkiye Yapay Zeka Akademisi

Specialized agent, belirli bir göreve, veri alanına veya araç setine odaklanacak şekilde tasarlanmış, **sınırlı ama derin uzmanlığa** sahip agent'tır.


1 Uzmanlaşma Mantığı



2 Neden Specialized Agent?



3 Uzmanlaşma Türleri



4 Tasarım Prensipleri ve Kısa Örnek



Manager / Supervisor Agent



Türkiye Yapay Zeka Akademisi

Manager / Supervisor agent, birden fazla uzman agent'ın görevlerini planlayan, uygun agent'a yönlendiren, ilerlemeyi izleyen ve ara sonuçları birleştirerek nihai çıktıyı yöneten **koordinatör agent**'tır.

1 Temel Sorumluluklar



Görev Yönlendirme

Gelen görevi analiz eder, uygun uzman agent'a yönlendirir.



Görev Dağıtımı

Büyük görevi alt görevlere böler ve agent'lara dağıtır.



İlerleme Takibi

Görev adımlarının durumunu ve ara sonuçları izler.



Sonuçları Birleştirme

Farklı agent'lardan gelen çıktıları bir araya getirerek nihai sonucu oluşturur.



Kalite Kontrol

Eksik, çelişkili veya düşük kaliteli sonuçları tespit eder ve gerekli düzeltmeleri sağlar.

2 Nasıl Çalışır?



3 Ne Zaman Kullanılır?



Görev çok adımlıysa

Planlama, araştırma, analiz ve yazım gibi birden fazla adım gerekiyorsa.



Birden fazla uzmanlık gerekiyorsa

Farklı yetkinliklere sahip birden fazla uzman agent kullanılacaksa.



Farklı tool ve veri kaynakları birlikte kullanılacaksa

Web, kurumsal dokümanlar, veritabanları gibi birden çok kaynak gerekiyorsa.



Denetim, review veya escalation önemliyse

Sonuçların kalite kontrolü, insan onayı veya üst seviyeye aktarım gerekiyorsa.

4 Teknik Terimler ve Güncel Kalıplar



Planner – Executor

Biri planlar, diğeri uygular.



Router

İşi doğru agent'a gönderir.



Supervisor pattern

Merkezi koordinasyon yapısıdır.



Critic / Reviewer

Ara çıktıyı denetleyen roldür.



Human-in-the-loop

Kritik adımda insan onayı alır.



Retry / Escalation

Başarısız görev tekrar denir veya başka agent'a aktarılır.

Örnek: Pazar araştırması sistemi — Supervisor, araştırma, veri, analiz ve yazım agent'larını koordine ederek tek bir yönetici özeti üretir.

Handoff



Türkiye Yapay Zeka Akademisi



Handoff, bir agent'ın belirli bir görev veya alt görev tamamlandığında, **mevcut durumu (bağlam, veriler, talimatlar)** **başka bir agent'a devrederek** sürecin kesintisiz şekilde devam etmesini sağlayan yöntemdir.




Handoff Örneği (Sadeleştirilmiş Akış)



Agents as Tools



Agents as Tools, bir ajanı başka bir ajanın kullanabileceği bir **araç (tool)** olarak tanımlayarak, belirli bir görevi yerine getirmesi için çağrılan ve sonucunu döndüren **yeniden kullanılabilir alt ajanlardır**.



Örnek Tool Ajanlar



Kullanım Senaryoları



Handoff ve Agents as Tools Farkı



Türkiye Yapay Zeka Akademisi



Handoff, görevin kontrolünü ve bağlamını başka bir agent'a devrederek süreçte yeni bir agent'ın devam etmesini sağlar; **Agents as Tools** ise bir agent'ı mevcut agent'ın kullanabileceği bir araç (tool) olarak çağırarak sonuç elde etmeyi sağlar.



Handoff

Görevin kontrolü başka bir agent'a devredilir.



Kullanıcı

"Bu proje için teknik tasarım yap ve ardından kodlamaya devam et."



Tasarım Agentı

- Gereksinimleri analiz eder
- Teknik tasarım hazırlar
- Görevi kodlama agent'ına devreder (handoff)



Kodlama Agentı

- Tasarım dokümanını alır
- Kodu yazar
- Testleri çalıştırır
- Sonucu üretir



Agents as Tools

Bir agent, mevcut agent'ın kullanabileceği bir araç olarak çağırılır.



Kullanıcı

"Rakip şirketleri araştır, bulguları analiz et ve strateji önerisi hazırla."



Ana Agent

- Görevi planlar
- Gerektiğinde alt agent'ları tool olarak çağırır
- Sonuçları birleştirir
- Nihai yanıtı üretir



Tool çağırısı (görev + parametreler)



Sonuç (yapılandırılmış çıktı)



Özellik	Handoff	Agents as Tools
Amaç	Görevin kontrolünü başka bir agent'a devretmek.	Belirli bir alt görevi gerçekleştirmek için bir agent'ı araç olarak çağırarak.
Çalışma Şekli	Mevcut agent, bağlamı (context) yeni agent'a aktarır ve görev devam eder.	Mevcut agent, ihtiyaca göre agent'ı çağırır, sonuç alır ve süreç kendisi devam eder.
Kontrol	Devredilen agent'ta olur (yeni agent devam eder).	Kontrol ana agent'ta kalır.
Bağlam (Context)	Genellikle önceki konuşma, veriler ve talimatlar yeni agent'a aktarılır.	Ana agent gerekli bilgileri parametre olarak gönderir (isteğe bağlı context).
Süreç	Uzun süreli veya ardışık görevlerde kullanılır.	Kısa, belirli ve tekrarlayan alt görevler için kullanılır.
Örnek	Analiz agent'ından kodlama agent'ına geçiş.	Araştırma agent'ını analiz yapmak için API gibi çağırma.
Avantaj	Uzmanlaşmış agent'lar arasında doğal görev devri.	Modüler, esnek, tekrarlanabilir ve kolay entegre edilebilir.
Dezavantaj	Bağlam aktarımı iyi yapılmazsa bilgi kaybı olabilir.	Sonuç kalitesi ana agent'ın tool kullanımı ve yönlendirmesine bağlıdır.
Ne zaman kullanılır?	Uzun ve ardışık görev akışlarında (analiz → tasarım → kodlama → test).	Belirli bir uzmanlık gerektiren alt görevlerde (web arama, veri analizi, raporlama vb.).

Agent Orchestration



Türkiye Yapay Zeka Akademisi



Agent Orchestration, birden fazla agent'ın birlikte çalışmasını **koordine eden, görevleri planlayan, yönlendiren, izleyen ve sonuçları birleştirerek** kullanıcıya nihai çıktıyı sunan yönetim katmanıdır.



Orchestration Desenleri



Centralized

Tek bir orchestrator tüm agent'ları yönetir.

En yaygın



Hierarchical

Üst seviye orchestrator alt orchestrator'ları yönetir.

Karmaşık görevler



Decentralized

Agent'lar kendi aralarında iletişim kurar.

Esnek, ölçeklenebilir



Hybrid

Merkezi yönetim + agent'lar arası iş birliği.

Büyük ölçekli sistemler



Orchestration'da Dikkat Edilenler



Task Decomposition

Görevi doğru alt görevlere ayırmak



Agent Selection

Uygun agent'ları seçmek



Dependency Management

Görevlerin bağımlılıklarını yönetmek



Parallel vs Sequential Execution

Hangi görevlerin paralel/sıralı çalışacağını belirlemek



Monitoring & Error Handling

Durum takibi, hata yönetimi, yeniden deneme



Result Synthesis

Sonuçları birleştirmek ve kalite kontrol



Popüler Framework ve Araçlar



LangGraph

State, routing, multi-agent



AutoGen (Microsoft)

Multi-agent conversation



Role-based multi-agent orchestration



LlamaIndex

Multi-agent RAG workflows



Semantic Kernel (Microsoft)

Agent orchestration + plugins



Multi-agent RAG pipelines



MCP Nedir ve Neden Kullanılır?

MCP Nedir ve Neden Kullanılır?



Türkiye Yapay Zeka Akademisi



MCP (Model Context Protocol), yapay zeka modellerinin ve agent'ların dış sistemlerdeki tool, veri ve kaynaklara **standart bir protokol** üzerinden erişmesini sağlayan yapıdır.



Model
modeli/agent'i temsil eder



Context
modele sunulan dış bilgi, tool ve kaynakları kapsar



Protocol
bu iletişimin standart kurallarla yapılmasını ifade eder



Neden Kullanılır?



Her servis için ayrı entegrasyon yazma ihtiyacını azaltır.

Farklı sistemlere bağlanmak için tekrar tekrar özel entegrasyon geliştirmeye gerek kalmaz.



Tool'ların standart şekilde keşfedilmesini ve kullanılmasını sağlar.

Mevcut tool'lar ve özellikleri standart bir formatta sunulur, kolayca keşfedilip kullanılabilir.



Agent uygulamalarının farklı sistemlere daha kolay bağlanmasına yardımcı olur.

Aynı yaklaşım ve protokolle farklı sistemlere entegrasyon yapılabilir.



Aynı tool katmanı birden fazla AI uygulaması tarafından yeniden kullanılabilir.

Bir kez tanımlanan tool'lar, farklı agent ve AI uygulamaları tarafından ortak şekilde kullanılabilir.



Normal Request / API Kullanımı vs MCP

Normal Request / API	MCP
Endpoint, auth ve format bilgisi geliştirici tarafından özel olarak yönetilir.	Tool açıklamaları ve parametreleri standart biçimde sunulur.
Her servis için ayrı entegrasyon gerekir.	Aynı protokolle farklı MCP server'lara bağlanılabilir.
Uygulama çoğu ayrıntıyı kendisi kodlar.	Agent uygun tool'u seçip çağırabilir.
API makinelere servis sunar.	MCP özellikle AI/agent entegrasyonu için tasarlanmıştır.

Normal Request / API



requests / özel entegrasyon



MCP



Örnekler



Hazır Kullanılan MCP Server



Filesystem MCP Server: dosya listeleme ve okuma



GitHub MCP Server: repo, issue, pull request işlemleri



Binance MCP Server: piyasa verileri ve desteklenen hesap işlemleri



Elle Tasarlanan / Custom MCP Server



Şirket içi sipariş sorgulama tool'ları



SQLite / PostgreSQL veritabanı erişimi



CRM, ERP veya destek sistemi entegrasyonları



AI Agent / LLM



MCP Client



MCP Server




API / Database / Files / Business Tools

MCP Mimarisi: Host, Client ve Server



Türkiye Yapay Zeka Akademisi



MCP Primitive'leri: Tools, Resources ve Prompts



Türkiye Yapay Zeka Akademisi



MCP primitive'leri, AI uygulamaları ile MCP server arasındaki temel etkileşim yapılarını tanımlar: **Tools** eylem yaptırır, **Resources** bilgi sağlar, **Prompts** ise hazır yönlendirme şablonları sunar.



Tools

Modelin veya agent'ın çağırabildiği, dış dünyada işlem yapan fonksiyonlardır.

- Input alır, işlem çalıştırır, sonuç döndürür
- Action / function calling mantığıyla kullanılır
- API, database, dosya sistemi veya business logic'e bağlanabilir



Örnekler

- `get_order_status(order_id)`
- `send_email(to, subject)`
- `create_ticket(issue)`



Ne zaman?

Bir iş yaptırmak veya sistem çağrısı yapmak gerektiğinde



Resources

Modelin okuyabildiği, bilgi veya içerik sağlayan veri kaynaklarıdır.

- Genellikle read-only bilgi sağlar
- Doküman, dosya, kayıt veya veri içeriği sunar
- Bağlam oluşturmak ve cevap kalitesini artırmak için kullanılır



Örnekler

- `company_policy.txt`
- `product_catalog.md`
- `customer_profile.json`



Ne zaman?

Modele okunacak güvenilir bilgi vermek gerektiğinde



Prompts

Önceden tanımlanmış, tekrar kullanılabilir yönlendirme veya görev şablonlarıdır.

- Belirli görevleri standartlaştırır
- İyi uygulamaları tekrar kullanılabilir hale getirir
- Kullanıcıya veya agent'a hazır çalışma çerçevesi sunar



Örnekler

- Özet çıkarma prompt'u
- Kod inceleme prompt'u
- Destek yanıtı oluşturma prompt'u



Ne zaman?

Sık tekrar eden görevler için tutarlı yönlendirme gerektiğinde

Kısa Karşılaştırma



Tools → işlem yapar



Resources → bilgi sağlar



Prompts → yönlendirme sunar

Basit zihinsel model



Agent / LLM



Prompts ile yönlendirilir



Resources ile beslenir



Tools ile aksiyon alır

Birden Fazla MCP Server Kullanımı



Türkiye Yapay Zeka Akademisi



Bir AI uygulaması veya agent, farklı yeteneklere ve veri kaynaklarına erişmek için **birden fazla MCP server'a aynı anda bağlanabilir** ve bu sayede modüler bir yapıda çalışır.



Neden birden fazla server?

- Uzmanlaşma:** Her MCP server belirli bir alanda uzman yetenekler sunar.
- Sorumlulukların ayrılması:** Farklı yetenekler modüler şekilde ayrılır.
- Güvenlik ve erişim kontrolü:** Veri kaynaklarına kontrollü ve izole erişim sağlanır.
- Yeniden kullanım ve ölçeklenebilirlik:** Aynı server'lar farklı uygulamalarda tekrar kullanılabilir ve kolayca genişletilebilir.



Çalışma mantığı



Kısa zihinsel model



Tek agent +



Birden fazla uzman MCP server +




Ortak ve standart erişim modeli



Human-in-the-Loop ve Guardrails


Agent Sistemlerinde Güvenlik Neden Farklıdır?

Bir agent, sadece metin üretmekle kalmayıp dış dünyadaki sistemlerle de etkileşime girebilir. Bu nedenle saldırı yüzeyi, saldırı vektörleri ve güvenlik gereksinimleri metin odaklı bir LLM'e göre çok daha geniştir.



Prompt Injection ve Indirect Prompt Injection

Prompt injection, modelin talimat hiyerarşisini bozarak istenmeyen davranış üretmeye yönlendirilmesidir; indirect prompt injection ise bu yönlendirmenin harici içerik üzerinden gelmesidir.



Tool Abuse ve Excessive Agency

Tool abuse, agent'ın sahip olduğu araçları yanlış veya uygunsuz biçimde kullanmasıdır; **excessive agency** ise agent'a görevi için gerekenden fazla yetki ve hareket alanı verilmesidir.

Tool Abuse



- 1 Tool doğru amaç dışında kullanılabilir.
- 2 Yanlış parametre veya gereksiz işlem üretilebilir.
- 3 Gerçek sistemlerde istenmeyen aksiyonlara yol açabilir.



Örnek

Kullanıcı: "Sipariş durumunu kontrol et."

Agent: `cancel_order()`
veya
`delete_record()`



Tipik sonuçlar



Yanlış işlem



Yetkisiz erişim



Politika ihlali

Excessive Agency



- 1 Agent'a ihtiyaçtan fazla tool verilir.
- 2 Karar alanı gereğinden fazla genişler.
- 3 Risk, tool abuse ihtimalini artırır.



Örnek

Sadece stok sorgulaması yapacak bir agent'a `update`, `delete` veya genel `SQL` çalıştırma yetkisi verilmesi.



Neden problem?



Kontrol azalır



Hata etkisi büyür



Savunma zorlaşır



Temel fark

Tool abuse bir davranış problemidir; excessive agency ise bu davranışı mümkün kılan fazla yetki problemidir.



Temel savunmalar



Least privilege



Tool bazlı izinler



Onay mekanizmaları



Sandbox / izolasyon

Least Privilege, Sandbox ve İzolasyon

Güvenli agent tasarımında least privilege, sandbox ve izolasyon; agent'ın yalnızca gerekli yetkilere sahip olmasını ve işlemlerinin sınırlandırılmış ortamlarda gerçekleşmesini sağlar.

1 Least Privilege

Agent'a yalnızca görev için gerekli en az tool, veri ve izin verilir.




- Gereksiz tool ve yetkiler kaldırılır.
- Okuma / yazma / silme izinleri ayrı düşünülür.
- Hata etkisi ve kötüye kullanım riski azalır.



Örnek: Stok sorgulayan bir agent'a sadece read yetkisi verilir; update veya delete yetkisi verilmez.

2 Sandbox

Agent veya çalıştırdığı kod, sınırlandırılmış kontrollü bir çalışma alanında tutulur.




- Belirli klasörlere veya kaynaklara erişim sınırlandırılır.
- Ağ, komut veya dosya işlemleri kısıtlanabilir.
- Agent hata yapsa bile sistemin geneline yayılması engellenir.



Örnek: Kod çalıştıran agent yalnızca /workspace klasöründe işlem yapabilir.

3 İzolasyon

Farklı agent, tool veya süreçlerin birbirinden ayrılmış biçimde çalıştırılmasıdır.



- Süreçler ve servisler birbirinden ayrılır.
- Bir bileşendeki hata diğerlerini doğrudan etkilemez.
- Güvenlik ve denetim daha kolay hale gelir.



Örnek: Dosya erişimi yapan servis ile veritabanı erişimi yapan servis ayrı ortamlarda çalıştırılır.



Birlikte etkisi

Least privilege yetkiyi azaltır; sandbox çalışma alanını sınırlar; izolasyon ise bileşenleri birbirinden ayırır.

Temel kazanımlar



Daha az yetki



Daha az saldırı yüzeyi



Sınırlı hata etkisi



Daha güvenli agent

Data Leakage



Türkiye Yapay Zeka Akademisi

Data leakage, agent veya bağlı olduğu sistemlerdeki hassas bilgilerin istemeden kullanıcıya, loglara, tool sonuçlarına veya harici servislere sızmasıdır.



Güvenli Agent Tasarım Prensipleri



Türkiye Yapay Zeka Akademisi

Güvenli agent tasarımı; yetkileri sınırlandıran, veriyi koruyan, tool kullanımını denetleyen ve kritik işlemlerde kontrol mekanizmaları kullanan sistem tasarımıdır.



Temel prensipler



Least privilege

yalnızca gerekli tool ve izinler



Data minimization

yalnızca gerekli veri context'e girer



Input / Output validation

girdi ve cevap kontrol edilir



Tool validation

parametre ve yetki kontrolü



Fail-safe default

emin değilse işlem yapma



Kontrol mekanizmaları



Human approval

kritik işlemlerde insan onayı



Guardrails

input, output ve tool korumaları



Sandbox / isolation

sınırlı çalışma ortamı



Logging / audit

ne oldu, ne çağrıldı izlenir



Rate / step limits

kontrolsüz döngü ve aşırı işlem engellenir



Güvenli tool tasarımı

Geniş tool

execute_sql(query)



Riskli

Dar tool

get_order_status(order_id)



Güvenli

Geniş dosya erişimi

read_any_file(path)



Riskli

Sınırlı erişim

read_invoice_pdf(invoice_id)



Güvenli



Dar kapsamlı, açık amaçlı tool tasarla



Serbest komut yerine iş odaklı fonksiyonlar kullan



Örnek güvenli akış

1

Kullanıcı isteği

2

Input kontrolü

3

Agent karar verir

4

Tool yetki / parametre kontrolü

5

Gerekirse insan onayı

6

Output filtreleme



Gizli veri tool sonucunda maskele



Harici içerikleri talimat gibi güvenme



Kritik işlemlerde onaysız aksiyon alma



Temel mesaj

Güvenli agent tasarımında amaç, agent'ın neyi görebileceğini, neyi yapabileceğini ve hangi koşullarda aksiyon alacağını sistematik olarak sınırlandırmaktır.



Human-in-the-Loop ve Guardrails

Guardrails: Input, Output ve Tool



Türkiye Yapay Zeka Akademisi



Guardrail, input, output ve tool kontrolleri için kullanılan bir kontrol katmanıdır; kural tabanlı yöntemler, sınıflandırıcı modeller veya dil modelleri ile uygulanabilir.



Hazır guardrail modelleri on-prem / local çalıştırılabilir; ancak şirketin özel yetki kurallarını kendiliğinden bilmez.



Classifier Model Nasıl Çalışır?

On-prem kullanılabilir

Örnek: Meta Prompt Guard 2

- Görev:** Prompt injection ve jailbreak tespiti
- Nasıl çalışır?:** Kullanıcı girdisini alır, eğitimde öğrendiği saldırı kalıplarına göre sınıflandırır.
- Çıktı:** Güvenli / Riskli veya Normal / Injection / Jailbreak
- Kullanım:** Özellikle input guardrail
- Yapı:** Küçük classifier modeli



Bu modelin neyi kontrol edeceği, eğitim sırasında öğrendiği genel örneklerden gelir; şirketin özel iş kurallarını kendiliğinden bilmez.



LLM Tabanlı Guardrail Nasıl Çalışır?

On-prem kullanılabilir

Örnek: Google ShieldGemma

- Görev:** İçerik güvenliği ve politika ihlali kontrolü
- Nasıl çalışır?:** İçeriği ve verilen policy/prompt'u birlikte değerlendirir.
- Çıktı:** Uygun mu / İhlal var mı (Yes / No veya Compliant / Violation)
- Kullanım:** Input ve output guardrail
- Yapı:** Open-weight güvenlik modeli / LLM tabanlı değerlendirme



Bu modelin neyi kontrol edeceği hem güvenlik eğitimi (safety training) hem de verilen policy/prompt'tan gelir.



Tool Guardrail Neden Ayır?

Kritik aksiyonlar (dosya silme, para transferi, harici sistem erişimi gibi) çoğunlukla yalnızca LLM'e bırakılmaz. Bu aksiyonlar deterministik kod / iş kuralları ile kontrol edilir.



Yetki kontrolü

Kullanıcının ilgili aksiyonu yapma yetkisi var mı?



Parametre doğrulama

Girdi parametreleri geçerli mi?



Limit kontrolü

Tutar, adet, süre gibi limitler aşıyor mu?



İnsan onayı

Yüksek riskli işlemlerde insan onayı gerekli mi?



```
if user.role != 'admin' -> deny
if amount > 10000 -> require approval
```



Hazır güvenlik modelleri semantik riski (zararlı içerik, politika ihlali) kontrol eder; kritik iş kuralları çoğunlukla kod ile uygulanır.



Kullanıcı



Meta Prompt Guard 2



ShieldGemma



Agent / LLM



Tool Guardrail



Tool

Injection?

Policy?

Yetki / Limit?